

Documentation :

Fiabilisation des SIRENs & SIRETs du référentiel FINESS

Mise en qualité de données



Destinataires

Prénom / Nom	Entité / Direction
ANS DOPS	

Documents de référence

Titre	Lien Sharepoint
Documentation technique – README	File Readme
Résultats du Matching direct (phase 1) – SN et ST	File excel
Résultats du Matching indirect (phase 2) - SN et ST	File excel
Résultats du Matching indirect approfondi (phase 3) - SN et ST	File excel
Résultats du Cohérence globale (lien entre EJ et EG valides)	File excel
Résultats du Cohérence par phase (lien entre EJ et EG valides)	File excel

Historique du document

Version	Rédigé par		Vérifié par		Validé par	
1.00	ANS – TS. ABDOULAYE	18/05/2026	ANS – TS. ABDOULAYE	02/06/2026	ANS -	Le
	Motif et nature de la modification : Initialisation du document					

SOMMAIRE

1. INTRODUCTION	5
1.1. Contexte.....	5
1.2. Historique du projet.....	5
1.2.1. Premiers travaux : sirenisation initiale	5
1.2.2. Reprise du chantier : exploration de la siretisation	5
1.2.3. Approche A : Record Linkage par Fuzzy Matching.....	5
1.2.4. Approche B : Record Linkage probabiliste augmenté par Deep Learning (Splink + embeddings).....	6
1.2.5. Abandon de Splink + embeddings	6
1.2.6. Décision finale : généralisation du Record Linkage par Fuzzy Matching	6
1.2.7. Reprise et enrichissement de la sirenisation.....	6
1.3. Objet et finalité	7
1.4. Chiffres de grandeur	7
2. ARCHITECTURE GLOBALE	7
2.1. Prétraitement des données.....	8
2.1.1. Normalisation des textes	8
2.1.2. Suppression des mots vides	9
2.1.3. Mapping des types de voie.....	9
2.1.4. Harmonisation par champ.....	9
2.2. Mesure des similarités	9
2.2.1. Similarité textuelle.....	9
2.2.2. Similarité basée sur les initiales.....	9
2.2.3. Similarité exacte.....	9
2.2.4. Calcul des scores combinés	9
2.2.5. Règle de validation	10
2.2.6. Statuts produits	10
3. PIPELINE SIRENISATION (EJ ↔ UL SIRENE).....	10
3.1. Phase 1 — Matching direct par SIREN	10
3.2. Phase 2 — Matching indirect probabiliste	11
3.2.1. Construction du périmètre A / B / C	11
3.2.2. Blocking et matching	11
3.2.3. Bonus de cohérence d'identifiant	11
3.3. Phase 3 — Matching approfondi	11
3.3.1. Blocking élargi.....	11
3.3.2. Score APE	11
3.3.3. Score date.....	12
3.3.4. Pondération adaptative.....	12
4. PIPELINE SIRETISATION (EG ↔ ETAB SIRENE)	12
4.1. Phase 1 — Matching direct par SIRET.....	12

4.2. Optimisation préalable : filtrage de la base SIRENE	13
4.3. Phase 2 — Matching indirect probabiliste	13
4.4. Phase 3 — Matching approfondi	13
5. COMPARAISON DES DEUX PIPELINES.....	13
5.1. Principe de la cohérence SIREN ↔ SIRET.....	13
5.2. Vue par EJ et ses EG (vue A).....	13
5.3. Source des données pour la comparaison	14
5.4. Excel produit.....	14
6. RESULTATS	15
6.1. Résultats sirenisation.....	16
6.2. Résultats siretisation	17
6.3. Résultats de la comparaison	18
7. CONCLUSION	19

1. INTRODUCTION

1.1. Contexte

Dans le cadre de la migration du référentiel FINESS vers FINESS+, plusieurs chantiers de mise en qualité des données ont été identifiés. Ces chantiers visent à améliorer la fiabilité des référentiels existants, à corriger les incohérences et à préparer les données en amont du déploiement.

Le rapprochement des référentiels FINESS et SIRENE constitue un chantier majeur de cette mise en qualité. Il s'appuie sur l'approche du Fuzzy Matching / Record Linkage afin d'identifier et de consolider les correspondances entre entités juridiques (EJ), établissements géographiques (EG) et le répertoire SIRENE de l'INSEE.

1.2. Historique du projet

Ce chantier s'est déroulé en plusieurs étapes successives, chacune apportant des enseignements méthodologiques qui ont orienté les choix techniques finaux.

1.2.1. Premiers travaux : sirenisation initiale

Une première version de la sirenisation des EJ FINESS a été développée par une collègue. Elle reposait sur une approche en deux phases :

- Phase 1 : matching direct via le numéro SIREN renseigné dans FINESS, avec validation par score de similarité
- Phase 2 : matching probabiliste indirect avec blocking par département pour les EJ sans SIREN ou rejetés en phase 1

Cette première version a permis d'atteindre un taux de fiabilisation d'environ 84 % des 54 054 EJ FINESS actives, en s'appuyant sur la similarité Levenshtein + Jaccard pour les champs textuels et la similarité exacte pour les champs structurants.

1.2.2. Reprise du chantier : exploration de la sirenisation

À la reprise du chantier, la priorité a été donnée à la sirenisation, c'est-à-dire au rapprochement des établissements géographiques (EG) FINESS avec les établissements SIRENE. Ce volet n'avait pas été traité dans la première version.

Deux approches techniques ont été comparées pour aborder cette nouvelle phase : une approche de Record Linkage par Fuzzy Matching (la même famille de méthodes que celle utilisée par la sirenisation initiale) et une approche plus avancée basée sur le Deep Learning, combinant Splink (record linkage probabiliste) et embeddings issus de modèles de langage.

1.2.3. Approche A : Record Linkage par Fuzzy Matching

Le Record Linkage par Fuzzy Matching consiste à calculer des scores de similarité par champ (nom, adresse) à partir de métriques classiques (distance de Levenshtein, indice de Jaccard, égalité stricte), puis à combiner ces scores selon une pondération métier pour produire un score global, comparé à des seuils de validation. C'est une approche éprouvée, largement documentée dans la littérature du Record Linkage, et bien adaptée aux référentiels structurés comme FINESS et SIRENE.

Avantages constatés :

- Méthode transparente : chaque décision est traçable et explicable
- Faible coût en ressources : exécution rapide sur des bases volumineuses sans GPU
- Maintenabilité : les règles métier peuvent être ajustées par les équipes
- Cohérence avec la sirenisation initiale : facilite la comparaison ultérieure

1.2.4. Approche B : Record Linkage probabiliste augmenté par Deep Learning (Splink + embeddings)

Cette seconde approche, plus puissante en théorie, combine deux briques issues du Deep Learning et du record linkage probabiliste.

Splink est une bibliothèque Python de record linkage probabiliste basée sur l'algorithme de Fellegi-Sunter. Contrairement au Fuzzy Matching qui repose sur des seuils fixés a priori, Splink estime les probabilités de correspondance entre paires d'entités à partir d'un modèle statistique entraîné sur les données elles-mêmes (expectation-maximization). Cette calibration statistique évite l'arbitraire du choix des seuils.

Les embeddings, issus du Deep Learning, consistent à représenter les chaînes textuelles (noms, adresses) sous forme de vecteurs numériques denses générés par des modèles de langage pré-entraînés (BERT, Sentence-Transformers, etc.). Là où la distance de Levenshtein ne mesure que la ressemblance caractère par caractère, les embeddings capturent la proximité sémantique : « CH » et « Centre Hospitalier » sont reconnus comme désignant la même chose, même si leur écriture diffère complètement.

La combinaison Splink + embeddings représente l'état de l'art du record linkage moderne et aurait pu apporter un gain qualitatif significatif sur les cas difficiles du chantier.

Apports théoriques attendus :

- Détection des correspondances sémantiquement proches mais textuellement différentes (« CH » vs « Centre Hospitalier », « HCL » vs « Hospices Civils de Lyon »)
- Probabilités de correspondance calibrées statistiquement plutôt que par seuils empiriques
- Modèle apprenant qui peut s'améliorer avec de nouvelles données d'entraînement
- Robustesse face aux variations d'écriture et aux fautes de saisie

1.2.5. Abandon de Splink + embeddings

Malgré l'intérêt théorique de cette approche, plusieurs contraintes techniques ont conduit à son abandon :

- Installation de PyTorch impossible dans l'environnement Jupyter mis à disposition (bibliothèque requise pour les modèles d'embeddings)
- Ressources matérielles insuffisantes : 16 Go de RAM sans GPU, alors que les modèles d'embeddings actuels en requièrent davantage pour des bases de plusieurs millions d'entités
- Volumétrie SIRENE prohibitive : plus de 15 millions d'établissements actifs à vectoriser, opération trop coûteuse en temps de calcul
- Risque de dépendance à un modèle d'IA dont les décisions seraient moins facilement auditable

Il aurait été particulièrement intéressant de poursuivre cette piste dans un environnement adapté (machine équipée d'un GPU, mémoire RAM supérieure à 32 Go, accès à des modèles d'embeddings spécialisés sur le domaine français de la santé). Le Deep Learning aurait probablement permis une fiabilisation plus fine sur les cas où le nom de l'entité est très différent entre FINESS et SIRENE tout en désignant la même structure — typiquement les cas où le Fuzzy Matching atteint ses limites par construction (deux chaînes sémantiquement identiques mais textuellement éloignées). Cette approche reste une perspective intéressante pour de futurs travaux d'amélioration du chantier.

1.2.6. Décision finale : généralisation du Record Linkage par Fuzzy Matching

Le Record Linkage par Fuzzy Matching a été retenu pour la suite du projet, et appliqué de manière généralisée et enrichie aux deux volets :

- Siretisation : nouveau chantier (EG ↔ Etab SIRENE) construit selon cette méthode
- Sirenisation : reprise complète des travaux initiaux pour intégrer les enrichissements méthodologiques (périmètre A/B/C, bonus de cohérence, phase 3 approfondie)

1.2.7. Reprise et enrichissement de la sirenisation

Les derniers travaux ont consisté à reprendre la sirenisation initiale pour l'aligner sur la nouvelle méthode de Record Linkage par Fuzzy Matching en 3 phases, et à mettre en cohérence les sorties des deux pipelines via un module de comparaison finale.

1.3. Objet et finalité

L'objet de ce chantier est de fiabiliser conjointement les numéros SIREN (associés aux entités juridiques) et SIRET (associés aux établissements géographiques) du référentiel FINESS, en assurant leur cohérence avec le répertoire SIRENE de l'INSEE.

La méthodologie repose sur :

- Un pipeline siretisation en 3 phases pour rapprocher chaque EG FINESS à son établissement SIRENE
- Un pipeline sirenisation en 3 phases pour rapprocher chaque EJ FINESS à son unité légale SIRENE
- Une étape finale de comparaison qui vérifie la cohérence SIREN ↔ SIRET entre les deux pipelines

1.4. Chiffres de grandeur

Le traitement porte sur :

- L'ensemble des EJ et EG FINESS actifs
- Les unités légales (UL) actives et les établissements actifs du référentiel SIRENE INSEE

Ordres de grandeur :

- Nombre d'EJ FINESS actifs : 54 097
- Nombre d'EG FINESS actifs : 104 612
- Nombre d'unités légales SIRENE actives : plus de 15 millions
- Nombre d'établissements SIRENE actifs : plus de 16 millions

Ces volumes ont justifié la mise en place :

- D'un traitement optimisé avec stockage parquet
- D'un blocking départemental ou communal selon les phases
- D'une approche progressive en plusieurs phases successives
- D'un filtrage de la base SIRENE pour la siretisation (réduction × 30 à × 50)


2. ARCHITECTURE GLOBALE

Le projet s'articule en trois volets complémentaires :

- Sirenisation : matching EJ FINESS ↔ Unités Légales SIRENE en 3 phases
- Siretisation : matching EG FINESS ↔ Établissements SIRENE en 3 phases (en miroir)
- Comparaison : vérification de la cohérence SIREN ↔ SIRET entre les deux pipelines

Le schéma présenté dans la suite du document propose une vision synthétique du projet. Il met en évidence les principales étapes de traitement ainsi que les résultats associés, notamment en termes de validation et de rejet.

Démarche du projet FINESS x SIRENE Mise en qualité des SIRET et SIREN par rapprochement avec INSEE



2.1. Prétraitement des données

Avant toute opération de rapprochement, un prétraitement est appliqué pour harmoniser les informations issues de FINESS et de SIRENE. Cette étape est essentielle pour réduire les variations d'écriture, améliorer la qualité des scores de similarité et limiter les faux négatifs.

2.1.1. Normalisation des textes

Une normalisation est appliquée à l'ensemble des champs textuels (raison sociale, type de voie, libellé de voie) :

- Conversion en majuscules
- Suppression des accents

- Suppression des caractères spéciaux et de la ponctuation
- Suppression des espaces multiples

2.1.2. Suppression des mots vides

Pour les champs de raison sociale et de dénomination, les mots vides peu discriminants sont supprimés :

- Formes juridiques : SA, SAS, SARL, EURL, SCI, SELARL, SELAS
- Mots de liaison : DE, DU, DES, LA, LE, LES, ET, EN, AU, AUX

2.1.3. Mapping des types de voie

Le champ type de voie fait l'objet d'un enrichissement par mapping pour uniformiser les abréviations :

- AV → AVENUE, BD → BOULEVARD, R → RUE
- CHE / CHEM → CHEMIN, PL → PLACE, RTE → ROUTE

2.1.4. Harmonisation par champ

Champ	Normalisation	Stop words	Mapping
Raison sociale / Dénomination	Oui	Oui	Non
Type de voie	Oui	Non	Oui
Libellé de voie	Oui	Non	Non
Numéro de voie	Non	Non	Non
Code commune	Non	Non	Non

2.2. Mesure des similarités

La mesure de similarité repose sur plusieurs approches complémentaires, adaptées à la nature des champs comparés.

2.2.1. Similarité textuelle

Utilisée pour les champs libres, elle combine deux métriques :

- Distance de Levenshtein : nombre minimal de modifications nécessaires pour passer d'une chaîne à l'autre
- Indice de Jaccard : ratio entre les mots communs et l'ensemble des mots distincts

$$\text{Score textuel} = 0,6 \times \text{Levenshtein} + 0,4 \times \text{Jaccard}$$

2.2.2. Similarité basée sur les initiales

Cette approche permet de gérer les abréviations courantes du secteur santé : APHP vs ASSISTANCE PUBLIQUE HOPITAUX DE PARIS, CHU vs CENTRE HOSPITALIER UNIVERSITAIRE, etc. Elle compare les initiales d'une chaîne avec une autre chaîne.

2.2.3. Similarité exacte

Utilisée pour les champs structurants (code commune, numéro de voie). Score de 100 si égalité stricte, 0 sinon.

2.2.4. Calcul des scores combinés

$$\text{Score_nom} = 0,6 \times \text{Score textuel} + 0,4 \times \text{Score initiales}$$

$$\text{Score_adresse} = 0,30 \times \text{code_commune} + 0,30 \times \text{numéro_voie} + 0,40 \times \text{similarité (type + libellé)}$$

$$\text{Score_global} = 0,4 \times \text{Score_nom} + 0,6 \times \text{Score_adresse}$$

2.2.5. Règle de validation

Une correspondance est considérée comme valide si elle respecte au moins l'une des deux conditions :

$$\text{Score_global} \geq 67$$

OU

$$\text{Score_nom} \geq 15 \text{ ET } \text{Score_adresse} \geq 55$$

2.2.6. Statuts produits

Statut	Condition
VALIDE_FORT	Validé et score_global $\geq$ 85
VALIDE	Validé (règle ci-dessus respectée)
DOUTEUX	Non validé, score_global $\geq$ 40
REJETE	Non validé, score_global $<$ 40
SANS_SIRET / SANS_SIREN	Identifiant non renseigné dans FINESS
SIRET_INCONNU / SIREN_INCONNU	Identifiant FINESS absent de SIRENE
SANS_CANDIDAT	Aucune correspondance dans la commune ou département

3. PIPELINE SIRENISATION (EJ ↔ UL SIRENE)

Le pipeline sirenisation associe chaque entité juridique (EJ) FINESS à une unité légale (UL) du répertoire SIRENE. Il s'organise en 3 phases progressives dont les rôles sont distincts : la Phase 1 est une phase de **validation** des données existantes, tandis que les Phases 2 et 3 sont des phases de **proposition** de candidats.

3.1. Phase 1 — Matching direct par SIREN

La Phase 1 est une phase de validation : elle ne cherche pas de nouveau SIREN, elle vérifie et confirme les SIREN déjà renseignés dans FINESS.

Pour chaque EJ FINESS disposant d'un numéro SIREN renseigné (nmsiren_stru) :

- Récupération de l'unité légale correspondante dans SIRENE par jointure exacte sur ce SIREN
- Calcul du score global de similarité (nom + adresse) pour confirmer que l'UL trouvée correspond bien à l'EJ
- Application de la règle de validation : si le score est suffisant, le SIREN est confirmé ; sinon, l'EJ est transmis aux phases suivantes

Cette phase est rapide et fiabilise massivement les EJ dont le SIREN est correctement renseigné dans FINESS. Elle ne produit aucun nouveau SIREN : elle se contente de valider ou d'invalider ce qui existe déjà.

3.2. Phase 2 — Matching indirect probabiliste

La Phase 2 est une phase de proposition : pour les EJ non résolus en Phase 1 (SIREN absent, invalide ou rejeté), on recherche dans SIRENE les UL les plus proches et on propose les meilleurs candidats.

3.2.1. Construction du périmètre A / B / C

Le périmètre des EJ à retraiter est segmenté en trois catégories pour optimiser le traitement :

- Périmètre A : EJ rattachés à au moins une EG (via nmfinsej_stru côté EG)
- Périmètre B : EJ non rattachés à une EG mais avec nmsiren_stru renseigné
- Périmètre C : EJ non rattachés à une EG et sans nmsiren_stru

3.2.2. Blocking et proposition de candidats

Le blocking s'effectue par commune (code INSEE à 5 chiffres) : pour chaque EJ, on ne compare qu'aux UL situées dans la même commune, ce qui réduit considérablement le volume de comparaisons.

Pour chaque EJ, on calcule un score de similarité avec toutes les UL du même bloc géographique, on trie par score décroissant et on retient les 5 meilleurs candidats. Parmi ces 5 candidats, seul le candidat de rang 1 est soumis à la règle de validation. S'il respecte le seuil, il est retenu comme SIREN validé pour cet EJ. S'il ne le respecte pas, l'EJ est transmis à la Phase 3.

3.2.3. Bonus de cohérence d'identifiant

Si le SIREN d'un candidat correspond au SIREN renseigné dans FINESS, un bonus de +15 points est appliqué à son score global. Ce bonus permet de remonter des candidats textuellement éloignés mais structurellement cohérents, qui auraient pu être sous-classés sans cela.

Important : le bonus est désactivé pour les EJ jumeaux dont le SIREN est déjà validé en Phase 1, afin d'éviter de booster artificiellement un candidat textuellement insuffisant.

3.3. Phase 3 — Matching approfondi

La Phase 3 est également une phase de proposition, mais avec un filet plus large et des critères de comparaison enrichis. Elle traite les EJ encore non résolus en Phase 2 en introduisant deux variables supplémentaires : le code APE et la date de création de l'unité légale.

3.3.1. Blocking élargi

Le blocking est élargi au département (2 premiers chiffres du code commune), pour capturer les EJ dont la commune renseignée dans FINESS et celle enregistrée dans SIRENE diffèrent légèrement (rattachement administratif récent, commune fusionnée, etc.).

Comme en Phase 2, les candidats sont triés par score décroissant. Le candidat de rang 1 est soumis à la règle de validation. S'il la respecte, il est retenu. Sinon, l'EJ est classé comme non rapproché (DOUTEUX, REJETE ou SANS_CANDIDAT selon le score obtenu).

3.3.2. Score APE

Le code APE (Activité Principale Exercée) renseigne sur la nature de l'activité de la structure. La comparaison s'effectue par niveau hiérarchique de la nomenclature NAF :

Cohérence APE	Score
Codes APE identiques	100
Même classe (4 premiers caractères)	70
Même groupe (3 premiers caractères)	40

Cohérence APE	Score
Même division (2 premiers caractères)	20
Pas de cohérence	0

3.3.3. Score date

La date de création de l'UL est comparée à la date d'ouverture de l'EJ FINESS :

Écart en années	Score
≤ 1 an	100
≤ 3 ans	80
≤ 5 ans	60
≤ 10 ans	40
≤ 20 ans	20
> 20 ans	0

3.3.4. Pondération adaptative

Ces deux critères supplémentaires ne sont pas toujours disponibles dans les données. La pondération s'adapte donc selon leur présence :

APE disponible	Date disponible	Pondération
Oui	Oui	$0,70 \times \text{global} + 0,20 \times \text{APE} + 0,10 \times \text{date}$
Oui	Non	$0,80 \times \text{global} + 0,20 \times \text{APE}$
Non	Oui	$0,80 \times \text{global} + 0,20 \times \text{date}$
Non	Non	Score global standard

4. PIPELINE SIRETISATION (EG ↔ ETAB SIRENE)

Le pipeline siretisation associe chaque établissement géographique (EG) FINESS à un établissement du répertoire SIRENE. Son architecture est en miroir de celle de la sirenisation, avec les mêmes 3 phases et la même logique de scoring.

4.1. Phase 1 — Matching direct par SIRET

Pour chaque EG FINESS disposant d'un numéro SIRET renseigné (nmsiret_stru) :

- Récupération de l'établissement correspondant dans SIRENE par jointure exacte sur le SIRET
- Calcul du score global de similarité (nom + adresse)

- Application de la règle de validation

Cette phase est exécutée sur la base SIRENE Etab complète (matching exact rapide).

4.2. Optimisation préalable : filtrage de la base SIRENE

Avant les phases 2 et 3, une optimisation cruciale est appliquée. La base SIRENE Etab compte plus de 16 millions d'établissements actifs, ce qui rend les calculs de similarité prohibitifs.

Solution : on construit un échantillon SIRENE filtré (étape ST-02bis) à partir des SIREN issus de la sirenisation :

- SIREN validés en sirenisation aux 3 phases (statuts VALIDE_FORT et VALIDE)
- SIREN candidats top 5 en sirenisation phase 2 (peu importe le statut)
- SIREN candidats top 3 en sirenisation phase 3 (peu importe le statut)

La réduction typique est de $\times 30$ à $\times 50$ ($16M \rightarrow$ environ 300k établissements). Cette optimisation rend les phases 2 et 3 de la sirenisation viables en environnement Jupyter.

4.3. Phase 2 — Matching indirect probabiliste

Cette phase traite les EG non résolus en P1. Elle applique :

- Un blocking par commune sur la base SIRENE filtrée
- Le calcul des scores nom et adresse selon les règles communes
- Le bonus +15 sur cohérence d'identifiant SIRET (avec désactivation pour les EG jumeaux)
- La sélection des 5 meilleurs candidats par EG

4.4. Phase 3 — Matching approfondi

Spécificité importante par rapport à la sirenisation : le critère date utiliser est la dateCreationEtablissement (et non la dateCreationUniteLegale). En effet, dans le pipeline sirenisation, on raisonne au niveau de l'établissement, pas au niveau juridique.

Les autres critères sont identiques à la sirenisation : blocking par département, score APE par niveau hiérarchique, pondération adaptative.

5. COMPARAISON DES DEUX PIPELINES

5.1. Principe de la cohérence SIREN $\leftrightarrow$ SIRET

Un SIRET est composé du SIREN de son unité légale parente suivi du NIC (Numéro Interne de Classement). Par construction, les 9 premiers chiffres d'un SIRET correspondent au SIREN.

La cohérence se vérifie donc ainsi : pour chaque EG validé en sirenisation, on récupère son EJ parent FINESSE (via la clé nmfinessej_stru côté EG) et on compare :

SIRET_EG_validé[:9] == SIREN_EJ_parent_validé ?

5.2. Vue par EJ et ses EG (vue A)

La vue de comparaison est construite par couple (EJ, EG). Chaque ligne représente un EG validé et son EJ parent, avec un verdict de cohérence.

Cinq statuts sont produits :

Statut	Signification
COHERENT	EG validé + EJ validé + SIRET_EG[:9] == SIREN_EJ
INCOHERENT	EG validé + EJ validé + SIRET_EG[:9] ≠ SIREN_EJ
PARTIEL_EG	EG validé mais EJ parent non validé en sirenisation
PARTIEL_EJ	EJ validé mais aucun EG validé associé
ORPHELIN	EG validé sans nmfinessej_stru renseigné

5.3. Source des données pour la comparaison

La comparaison s'appuie directement sur les 3 fichiers de phase de chaque pipeline (P1, P2 rang 1, P3 rang 1) qui sont fusionnés à la volée selon la logique suivante :

- Phase 1 : toutes les lignes
- Phase 2 (rang 1 uniquement) : on garde les entités non validées en P1
- Phase 3 (rang 1 uniquement) : on garde les entités non validées en P1 ni P2

Cette approche garantit l'intégrité des colonnes (notamment la clé nmfinessej_stru), qui pouvait être altérée lorsqu'on passait par une consolidation finale intermédiaire.

5.4. Excel produit

Le module de comparaison produit deux fichiers Excel complémentaires :

coherence_globale.xlsx — 4 feuilles :

- Synthèse : indicateurs globaux au niveau EJ
- Coherent : tous les couples (EG, EJ) cohérents, toutes colonnes remplies
- Incoherent : couples à investiguer (SIRET[:9] ≠ SIREN_EJ)
- Partiel : EG ou EJ validé d'un seul côté, avec colonne cote_valide précisant lequel


coherence_par_phase.xlsx — 8 feuilles, permettant d'analyser la qualité de la cohérence selon la phase de validation de chaque couple :

- Synthèse : deux tableaux — répartition des couples par feuille et vue par EJ uniques
- Coherent_P1 : couples cohérents où EJ et EG ont tous deux été validés en Phase 1 (les plus fiables)
- Coherent_P2 : couples cohérents où EJ et EG ont tous deux été validés en Phase 2
- Coherent_P3 : couples cohérents où EJ et EG ont tous deux été validés en Phase 3
- Coherent_Autres : couples cohérents avec phases mixtes (ex. EJ validé en P1, EG en P2)
- Incoherent : couples incohérents, toutes phases confondues
- Partiel_EJ : EJ validés sans aucun EG validé associé
- Partiel_EG : EG validés sans EJ parent validé

Cette décomposition par phase permet d'évaluer la fiabilité relative des couples cohérents : un couple Coherent_P1 (les deux identifiants existaient déjà et ont été confirmés par validation directe) est intrinsèquement plus sûr qu'un couple Coherent_P3 (les deux identifiants ont été proposés par le pipeline après trois phases de recherche).

6. RESULTATS

Avant d'entrer dans le détail des résultats par volet, le schéma ci-dessous présente une vue synthétique de l'ensemble du pipeline et de ses résultats. Il permet de lire d'un seul coup d'œil les volumes traités à chaque phase, les taux de validation obtenus, et les conclusions de la comparaison de cohérence finale.




Lecture du schéma : le pipeline est organisé en deux volets parallèles (sirenisation à gauche, siretisation à droite), chacun composé de trois phases progressives. La Phase 1 est une phase de validation des identifiants déjà présents dans FINESS : elle confirme ou invalide les SIREN et SIRET existants. Les Phases 2 et 3 sont des phases de proposition : elles recherchent les meilleurs candidats dans SIRENE pour les entités non résolues en Phase 1, et retiennent le candidat de rang 1 s'il respecte le seuil de validation fixé. Les résultats de chaque volet sont ensuite croisés dans une étape de vérification de cohérence : pour chaque couple (EJ, EG), on vérifie que les 9 premiers chiffres du SIRET validé correspondent bien au SIREN validé de l'EJ parent. Les chiffres détaillés par volet sont présentés dans les sections suivantes.

6.1. Résultats sirenisation


La sirenisation a permis de fiabiliser 51 953 EJ FINESS sur les 54 097 actifs, soit un taux de 96 %.

Répartition des statuts — Sirenisation



Détail par statut :


Statut	Phase 1	Phase 2	Phase 3	Synthèse totale
VALIDE_FORT	21 042	2 674	3	23 719
VALIDE	17 236	10 027	971	28 234
DOUTEUX	6 805	2 994	2 098	2 098
REJETE	2 885	115	46	46
SANS_SIREN	2 098	—	—	—
SIREN_INCONNU	4 032	—	—	—
SANS_CANDIDAT	—	9	—	—
TOTAL	54 097	15 819	3 118	54 097



6.2. Résultats sirenisation

La sirenisation a permis de fiabiliser 93561 EG FINESS sur les 104 612 actifs, soit un taux de 89,40 %.


Répartition des statuts — Sirenisation



Détail par statut :

Statut	Phase 1	Phase 2	Phase 3	Synthèse totale
VALIDE_FORT	21 605	4 764	1	26 370
VALIDE	38 121	26 960	2 110	67 191
DOUTEUX	10 615	10 714	10 070	10 070
REJETE	8 944	2 218	981	981
SANS_SIRET	13 129	—	—	—

Statut	Phase 1	Phase 2	Phase 3	Synthèse totale
SIRET_INCONNU	12 198	—	—	—
SANS_CANDIDAT	—	230	—	—
TOTAL	104 612	44 886	13 162	104 612



6.3. Résultats de la comparaison


Le croisement des deux pipelines produit les résultats suivants au niveau couples (EG, EJ) :

Statut de cohérence	Nombre
COHERENT	78 198
INCOHERENT	13 947

Au niveau EJ :

Indicateur	Nombre
EJ avec tous leurs EG cohérents	40 137
EJ avec au moins un EG incohérent	6 096
EJ validés sans aucun EG validé	5 720
EJ non validés mais avec EG validés	1 416

Synthèse de la cohérence SIREN ↔ SIRET



7. CONCLUSION

L'algorithme de fiabilisation mis en œuvre, reposant sur une approche de Record Linkage par Fuzzy Matching en 3 phases progressives, a permis d'atteindre un niveau élevé de qualité dans l'appariement des structures FINESS avec le référentiel SIRENE, et ce sur les deux volets : sirenisation des EJ et sretisation des EG.

Les principaux apports méthodologiques de ce chantier par rapport à la version initiale sont :

- L'introduction d'un nouveau pipeline sretisation complet, là où seule la sirenisation existait
- L'ajout d'un périmètre A/B/C sur la sirenisation pour cibler les EJ à retraiter
- L'ajout d'un bonus de cohérence d'identifiant en phase 2 (+15 si SIREN/SIRET FINESS et candidat correspondant)
- L'ajout d'une phase 3 approfondie utilisant le code APE et la date de création comme critères supplémentaires
- L'ajout d'un module de comparaison finale qui vérifie la cohérence SIREN ↔ SIRET entre les deux pipelines, fournissant un Excel à 4 feuilles directement exploitable par les équipes métier

Le Record Linkage par Fuzzy Matching retenu présente l'avantage d'être transparent, traçable et maintenable. Chaque décision est explicable par une combinaison de règles métier clairement définies, ce qui facilite l'audit et l'évolution du référentiel.


Le test exploratoire de l'approche Deep Learning (Splink + embeddings), bien que non retenu pour des raisons matérielles, ouvre une perspective intéressante pour de futurs travaux : dans un environnement disposant d'un GPU et de davantage de mémoire, cette approche pourrait permettre une fiabilisation encore plus fine, notamment sur les cas de noms textuellement éloignés mais sémantiquement proches — précisément les cas où le Fuzzy Matching atteint ses limites par construction.

L'ensemble de ce travail constitue une base solide pour les chantiers de mise en qualité à venir, et s'inscrit pleinement dans la dynamique de préparation au déploiement de FINESS+.

Annexe A : Démarche expérimentale du projet — historique complet

Le schéma ci-dessous retrace l'ensemble de la démarche suivie depuis l'exploration initiale jusqu'à l'architecture finale retenue. Il illustre les choix techniques effectués à chaque étape, les blocages rencontrés et les pivots stratégiques opérés, notamment l'abandon de l'approche sémantique (Splink + embeddings) au profit d'un Fuzzy Matching approfondi.

Schéma historique de la démarche projet FINESSE x SIRENE



Ce schéma se lit de haut en bas selon quatre grandes étapes :

- **Étape 1 — Exploration initiale** : identification du besoin, mise en place de la sirementisation v1 et test de la double approche AF/SF
- **Étape 2 — Tentative sémantique** : évaluation de Splink + embeddings, blocage technique, décision stratégique de rester sur le Fuzzy Matching
- **Étape 3 — Projet unifié final** : architecture en deux volets parallèles (sirementisation + sirementisation), un seul flux, trois phases par volet
- **Étape 4 — Cohérence finale** : croisement des résultats des deux volets, production du rapport qualité

Annexe B : comparaison des modèles d'embeddings testés

Cette annexe présente, à titre de complément, les différents modèles d'embeddings testés lors de l'exploration de l'approche de record linkage basée sur embeddings et Splink. Le tableau récapitule les principales caractéristiques observées pour chaque modèle : type de modèle, taille, source, faisabilité d'installation, temps d'encodage estimé, consommation mémoire et score de similarité sémantique. Il permet ainsi de conserver une trace synthétique des essais réalisés et des contraintes rencontrées.

Modèle	Type	Pa- rams (M)	Source	Installation (local)	Enco- dage (s)	RAM delta (Mo)	Sim. Sé- man- tique	Verdict
distiluse-base-multi- lingual-cased-v1	Multilingue (50 langues)	135	https://hugging-face.co/sentence-transformers/distiluse-base-multilingual-cased-v1	OK	10,2	301	0,788	~71h esti- mées sur 16M étab
CATIE-AQ/distilcam- embert-base-embed- ding	Français (DistilCa- memBERT)	67	https://hugging-face.co/CATIE-AQ/distilcamembert-base-embedding	OK	9	222	0,714	~60h esti- mées sur 16M étab
paraphrase-multilin- gual-MiniLM-L12-v2	Multilingue très léger (50 langues)	118	https://hugging-face.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2	OK	4,9	341	0,822	~24h esti- mées sur 16M étab
paraphrase-multilin- gual-mpnet-base-v2	Multilingue (50 langues)	278	https://hugging-face.co/sentence-transformers/paraphrase-multilingual-mpnet-base-v2	OK	16,2	481	0,794	~98h esti- mées sur 16M étab
almanach/camem- bert-bio-base	Français bio- médical	110	https://hugging-face.co/almanach/camembert-bio-base	OK	17	136	0,855	~115h es- timées sur 16M étab
Dr-BERT/DrBERT- 7GB	Français mé- dical (lourd)	110	https://hugging-face.co/Dr-BERT/DrBERT-7GB	OK				charge- ment im- possible