

Estimation de la qualité de l'appariement entre les entités juridiques FINESS et les SIREN proposés

Estimation fondée sur le plan de sondage ; adaptation de l'intervalle de confiance de Wilson pour une population finie

Antoine Blot

1 Objectif

L'objectif est d'estimer, dans un sous-ensemble donné de FINESS ou d'une version corrigée de FINESS, la proportion d'entités juridiques pour lesquelles l'appariement avec le SIREN proposé est correct, et de quantifier l'incertitude d'échantillonnage associée à cette estimation.

Dans le sous-ensemble étudié, un échantillon aléatoire simple d'entités juridiques est tiré sans remise, puis soumis à un contrôle manuel.

Chaque entité possède un état fixe, mais initialement inconnu : le SIREN proposé est soit correct, soit incorrect. Le contrôle manuel permet d'observer cet état pour les entités échantillonnées. L'analyse est donc fondée sur le plan de sondage : les valeurs de la population sont considérées comme fixes, et l'aléa provient du plan de sondage. Aucun modèle probabiliste décrivant les états de validité des entités n'est nécessaire.

2 Notations

Considérons un sous-ensemble donné de FINESS. Soit

- N le nombre total d'entités dans le sous-ensemble ;
- n le nombre d'entités échantillonnées, avec $1 \leq n \leq N$;
- $Y_i \in \{0, 1\}$ l'indicatrice du fait que le SIREN proposé pour l'entité i est correct ;
- $M = \sum_{i=1}^N Y_i$ le nombre inconnu de propositions correctes dans le sous-ensemble ;
- X le nombre observé de propositions correctes parmi les n entités échantillonnées.

Le paramètre d'intérêt est la proportion dans la population finie :

$$P = \frac{M}{N}. \quad (1)$$

3 Distribution d'échantillonnage

Dans le sous-ensemble étudié, n entités sont tirées sans remise parmi N entités, dont M ont une proposition correcte. Le nombre de propositions correctes dans l'échantillon suit donc une loi hypergéométrique (Pennsylvania State University, n.d.a) :

$$X \sim \mathcal{H}(N, M, n). \quad (2)$$

Pour le vérifier, supposons que $X = x$. Il existe $\binom{M}{x}$ façons de choisir les entités échantillonnées dont la proposition est correcte, et $\binom{N-M}{n-x}$ façons de choisir les autres entités de l'échantillon. Comme tous les échantillons de taille n sont équiprobables,

$$\Pr(X = x) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}, \quad (3)$$

pour toute valeur entière admissible de x .

Cette distribution se distingue du modèle binomial parce que le tirage est effectué sans remise : après la sélection d'une entité, la composition de la population restante est modifiée.

4 Estimateur et variance

L'estimateur naturel de P est la proportion observée dans l'échantillon.

Estimation ponctuelle
$\hat{P} = \frac{X}{n}. \quad (4)$

Dans le cadre d'un sondage aléatoire simple sans remise, $\mathbb{E}(X) = nM/N = nP$. Par conséquent,

$$\mathbb{E}(\hat{P}) = P, \quad (5)$$

de sorte que l'estimateur est sans biais (Pennsylvania State University, n.d.b).

Pour $N > 1$, la variance de la loi hypergéométrique est

$$\text{Var}(X) = nP(1-P)\frac{N-n}{N-1}. \quad (6)$$

Il s'ensuit que

$$\text{Var}(\hat{P}) = \frac{P(1-P)}{n} \frac{N-n}{N-1}. \quad (7)$$

Le facteur $(N-n)/(N-1)$ est la correction de variance pour population finie. Il est proche de 1 lorsque le taux de sondage est faible et vaut 0 lorsque toutes les entités du sous-ensemble sont soumises au contrôle manuel.

Comme P est inconnu, la variance doit être estimée. Pour des observations binaires, l'estimateur usuel sans biais, fondé sur le plan de sondage, dans le cadre d'un sondage aléatoire simple sans remise est donné ci-dessous, ainsi que son erreur-type estimée (Pennsylvania State University, n.d.b).

Variance estimée et erreur-type estimée
$\widehat{\text{Var}}(\hat{P}) = \frac{N-n}{N} \frac{\hat{P}(1-\hat{P})}{n-1}, \quad n > 1, \quad (8)$
$\widehat{\text{SE}}(\hat{P}) = \sqrt{\frac{N-n}{N} \frac{\hat{P}(1-\hat{P})}{n-1}}, \quad n > 1. \quad (9)$

Une démonstration à partir de la formule générale fondée sur la variance empirique est donnée à l'annexe A. Si $n = N$, le sous-ensemble est contrôlé exhaustivement et la variance d'échantillonnage est nulle. Si $n = 1 < N$, la variance au sein de l'échantillon, et donc cet estimateur de l'erreur-type, ne peuvent pas être calculés à partir des seules données du contrôle manuel. L'intervalle de type score présenté ci-dessous reste algébriquement défini dans ce cas, mais son approximation peut être médiocre.

5 Intervalle de confiance

Pour le sous-ensemble étudié, une procédure d'intervalle de confiance de niveau nominal 95 % est conçue pour contenir la valeur fixe P dans environ 95 % des échantillons aléatoires simples répétés qui pourraient être tirés dans ce sous-ensemble.

5.1 Pourquoi ne pas utiliser l'intervalle de Wald

L'intervalle de Wald usuel est

$$\hat{P} \pm z_{0.975} \widehat{SE}(\hat{P}), \quad (10)$$

où $z_{0.975} \approx 1.96$. Il est simple à calculer, mais peut dépasser les bornes de $[0, 1]$, présenter une probabilité de couverture insuffisante pour les petits échantillons ou les proportions proches de 0 ou de 1, et se réduire à un intervalle de largeur nulle lorsque $\hat{P} \in \{0, 1\}$. Ces défauts sont particulièrement importants ici, car certains sous-ensembles peuvent présenter une proportion très élevée de SIREN corrects et produire des échantillons dans lesquels aucune erreur n'est observée.

5.2 Intervalle de score de Wilson

L'intervalle de score de Wilson est obtenu par inversion d'un test du score. Au lieu d'estimer la variance à partir de $\hat{P}$, il évalue la variance sous chaque valeur candidate p . Dans le cadre binomial usuel, les valeurs candidates retenues vérifient

$$\frac{(\hat{P} - p)^2}{p(1 - p)/n} \leq z_{0.975}^2. \quad (11)$$

La résolution de cette inéquation conduit à un intervalle asymétrique qui reste contenu dans $[0, 1]$ et ne se réduit pas à un point lorsque toutes les observations échantillonnées ont la même valeur (Wilson, 1927; Brown et al., 2001).

5.3 Adaptation à une population finie

Dans le cadre d'un sondage aléatoire simple sans remise, la variance exacte sous le plan de sondage, évaluée pour une proportion candidate p dans la population finie, est réduite par le facteur

$$c = \frac{N - n}{N - 1}, \quad N > 1. \quad (12)$$

Une approximation naturelle de type score consiste donc à remplacer le dénominateur de l'équation (11) par $p(1 - p)c/n$:

$$\frac{(\hat{P} - p)^2}{p(1 - p)c/n} \leq z_{0.975}^2. \quad (13)$$

Cette construction est algébriquement équivalente à l'intervalle portant sur la proportion de l'ensemble de la population finie, établi par O'Neill (2021, section 2). De manière équivalente, il s'agit d'un intervalle de Wilson usuel reposant sur la taille d'échantillon effective, au sens algébrique,

$$n^* = \frac{n}{c} = n \frac{N - 1}{N - n}, \quad n < N, \quad (14)$$

bien que n^* ne corresponde pas à un nombre réel d'observations indépendantes.

Pour le calcul, définissons la grandeur sans dimension suivante.

Paramètre de Wilson avec correction pour population finie
$a = \frac{z_{0.975}^2 c}{n} = \frac{z_{0.975}^2}{n} \frac{N - n}{N - 1}, \quad N > 1. \quad (15)$

L'équation (13) est alors équivalente à

$$(1 + a)p^2 - (2\hat{P} + a)p + \hat{P}^2 \leq 0. \quad (16)$$

Comme $1 + a > 0$, l'inéquation est vérifiée entre les deux racines de l'équation du second degré correspondante. La formule quadratique fournit donc l'intervalle de score de Wilson approximatif avec correction pour population finie.

Intervalle de confiance de score de Wilson approximatif à 95 % avec correction pour population finie

$$\left[\frac{\hat{P} + \frac{a}{2} - \sqrt{a\hat{P}(1-\hat{P}) + \frac{a^2}{4}}}{1+a}, \frac{\hat{P} + \frac{a}{2} + \sqrt{a\hat{P}(1-\hat{P}) + \frac{a^2}{4}}}{1+a} \right], \quad a = \frac{z_{0.975}^2}{n} \frac{N-n}{N-1}. \quad (17)$$

Cet intervalle est approximatif pour deux raisons. Premièrement, il repose sur une approximation normale de la statistique de score en population finie. Deuxièmement, il traite p comme une variable continue, alors que la proportion réelle dans la population finie ne peut prendre que les valeurs $0, 1/N, \dots, 1$. Sa probabilité de couverture effective sous le plan de sondage n'est donc pas nécessairement égale à 95 %. Si $n = N$, l'incertitude d'échantillonnage disparaît et l'intervalle est défini par $[\hat{P}, \hat{P}]$.

6 Hypothèses et limites

1. À chaque application de la procédure, les entités du sous-ensemble soumises au contrôle manuel sont supposées sélectionnées par sondage aléatoire simple sans remise. Si la sélection est informative ou fait intervenir des probabilités d'inclusion inégales, l'estimateur et les formules de variance peuvent ne plus être valides.
2. Le contrôle manuel est supposé déterminer sans erreur si le SIREN proposé est correct. Les intervalles quantifient uniquement l'incertitude d'échantillonnage ; ils ne prennent en compte ni les erreurs de décision lors du contrôle manuel, ni l'incertitude liée à la définition ou à la constitution du sous-ensemble étudié.
3. L'approximation peut être imprécise lorsque l'échantillon ou la partie non échantillonnée de la population est de petite taille. Si une garantie de couverture en échantillon fini est nécessaire, il est possible d'inverser directement des tests fondés sur la loi hypergéométrique (Buonaccorsi, 1987). En raison du caractère discret de cette loi, les intervalles ainsi obtenus sont généralement conservateurs, et plusieurs constructions exactes sont possibles.

7 Conclusion

Lorsqu'elle est appliquée à un sous-ensemble de FINNESS, la procédure conduit à un nombre de propositions correctes suivant une loi d'échantillonnage hypergéométrique, et la proportion observée $\hat{P}$ est un estimateur sans biais de la proportion correspondante dans ce sous-ensemble de taille finie. L'intervalle de score de Wilson avec correction pour population finie de l'équation (17) tient compte de la réduction de la variance d'échantillonnage due au tirage sans remise, reste contenu dans $[0, 1]$ et évite les principaux défauts de l'intervalle de Wald. Il doit néanmoins être présenté comme un intervalle approximatif de niveau nominal 95 %, une approche exacte fondée sur la loi hypergéométrique restant possible.

A Justification de la formule de l'estimateur de variance

Dans le cadre d'un sondage aléatoire simple sans remise, l'estimateur général sans biais de la variance d'une moyenne d'échantillon est (Pennsylvania State University, n.d.b)

$$\widehat{\text{Var}}(\hat{P}) = \left(1 - \frac{n}{N}\right) \frac{s^2}{n}, \quad (18)$$

où

$$s^2 = \frac{1}{n-1} \sum_{i \in \mathcal{S}} (Y_i - \hat{P})^2, \quad n > 1, \quad (19)$$

et où $\mathcal{S}$ désigne l'ensemble des entités échantillonnées.

Comme $Y_i \in \{0, 1\}$, le numérateur de s^2 peut être décomposé entre les X entités échantillonnées telles que $Y_i = 1$ et les $n - X$ entités échantillonnées telles que $Y_i = 0$. Puisque $X = n\hat{P}$,

$$\begin{aligned} \sum_{i \in \mathcal{S}} (Y_i - \hat{P})^2 &= X(1 - \hat{P})^2 + (n - X)\hat{P}^2 \\ &= n\hat{P}(1 - \hat{P})^2 + n(1 - \hat{P})\hat{P}^2 \\ &= n\hat{P}(1 - \hat{P}). \end{aligned}$$

Par conséquent,

$$s^2 = \frac{n}{n-1} \hat{P}(1 - \hat{P}), \quad n > 1. \quad (20)$$

En substituant cette expression dans l'équation (18), on obtient l'équation (8). Les facteurs de correction pour population finie, d'apparence différente dans les équations (7) et (8), s'expliquent par l'application de la correction de Bessel à la variance empirique, qui conduit à utiliser $n - 1$ au dénominateur.

Références

- Pennsylvania State University. (n.d.a). STAT 414 : Introduction to Probability Theory. Lesson 7, Section 7.4 : Hypergeometric Distribution. Notes de cours en ligne. <https://online.stat.psu.edu/stat414/Lesson07>. Consulté le 23 juillet 2026.
- Pennsylvania State University. (n.d.b). STAT 506 : Sampling Theory and Methods. Lesson 2, Section 2.2 : Confidence Intervals for Population Proportion. Notes de cours en ligne. <https://online.stat.psu.edu/stat506/Lesson02>. Consulté le 23 juillet 2026.
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209–212. doi :10.1080/01621459.1927.10502953.
- Brown, L. D., Cai, T. T., and DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science*, 16(2), 101–133. doi :10.1214/ss/1009213286.
- O'Neill, B. (2021). Mathematical properties and finite-population correction for the Wilson score interval. Preprint, arXiv :2109.12464. doi :10.48550/arXiv.2109.12464.
- Buonaccorsi, J. P. (1987). A note on confidence intervals for proportions in finite populations. *The American Statistician*, 41(3), 215–218. doi :10.1080/00031305.1987.10475484.